数据库的自然语言接口关键技术研究

胡玮文

华南理工大学

2020/6/2

2020-06-04

数据库的自然语言接口

- 大家好
- 自我介绍
- 题目

Time: 00:18

目录

Time: 00:25

目录

数据库的自然语言接口

日常生活中，人们每天都在和无数数据库打交道

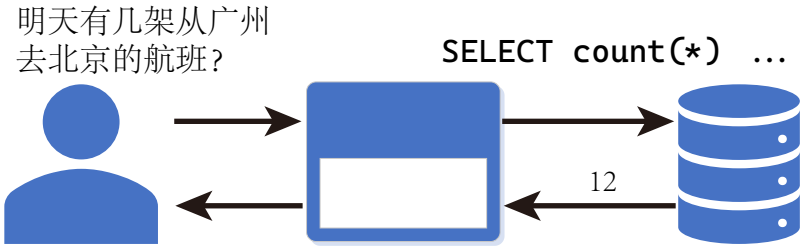

图: 当前与数据库交互的方式

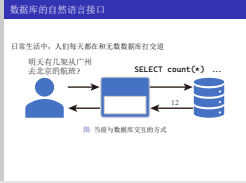

普通用户通过用户界面与数据库交互

Time: 01:00

数据库的自然语言接口

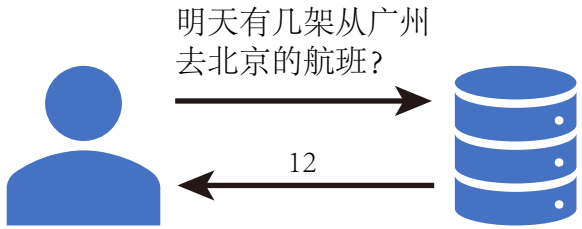

图: 通过自然语言接口与数据库直接交互

意义

广大用户首次获得了直接面对大数据的能力

大数据时代，数据产生快，分析数据水平不够。帮助用户获取分析任何信息，探索。
如何实现？（过渡）

Time: 01:25

自然语言到 SQL 转换任务

实现数据库的自然语言接口的方式之一：将自然语言转换为 SQL

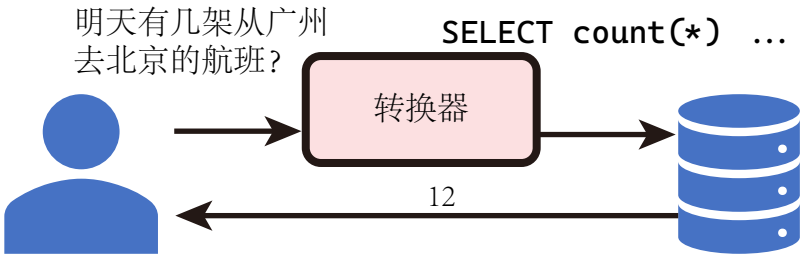

图: 通过自然语言到 SQL 转换与数据库交互

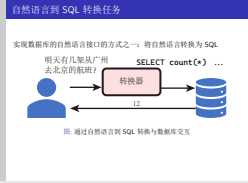

方法之一。所有现有数据库都能获得自然语言接口的能力。
目标：构建一个这样的转换器
过渡：为了实现这个目标，之前也有不少努力。
Time: 01:45

SParC 数据集

SParC 数据集是跨领域的，上下文相关的自然语言到 SQL 转换任务数据集

What are all the airlines?

```
SELECT * FROM AIRLINES
```

Of these, which is Jetblue Airways?

```
SELECT * FROM AIRLINES WHERE
Airline = "JetBlue Airways"
```

What is the country corresponding it?

```
SELECT Country FROM AIRLINES WHERE
Airline = "JetBlue Airways"
```

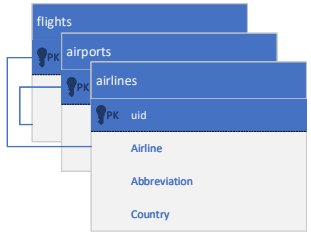

图: 数据库架构

- 内容包括 200 数据库架构，训练和推理时不重叠
- 以及多轮与数据库的交互
- 每轮交互包括一个自然语言的查询和对应的 SQL 语句
- 目标：构建转换器，输入：数据库架构，自然语言查询。输出：对应 SQL 语句

Time: 02:30

目录

目录
背景
提出的方法
SQL 预处理和后处理
上下文编码机制
关系编码机制
实验
结论

整体架构

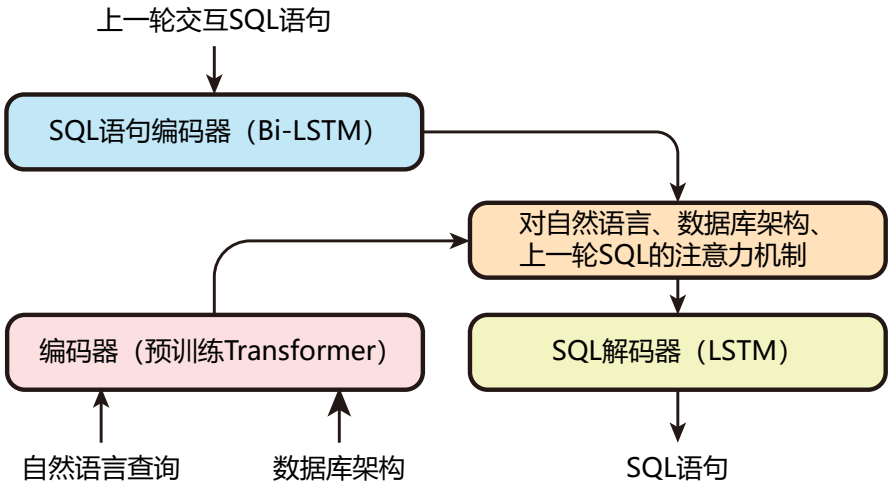

图: 模型整体架构

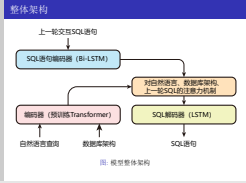

基于 EditSQL，主要：编码器、解码器。属于 Seq2Seq

过渡：后面主要介绍本研究中的改进内容

Time: 02:50

SQL 预处理和后处理

- SQL 中包含冗余的，抽象层次低的结构，将显著影响模型预测的准确率
- EditSQL 的方案为去除 SQL 中最为冗余的 FROM 子句，但并非所有 FROM 的内容都是冗余的。17.3% 的 SQL 无法还原

例 (去掉 FROM 子句后将丢失信息)

Which students have pets?

```
SELECT DISTINCT T1.fname
    FROM student AS T1
    JOIN has_pet AS T2 ON T1.stuid = T2.stuid
```

转换为

```
SELECT DISTINCT student.fname
```


Time: 03:50

SQL 预处理和后处理

本文方案

更细粒度地处理 FROM 子句，保留必要的信息。仅 2.3% 的 SQL 无法还原

预处理过程

1. 解析列引用，将引用表达式替换为“表名. 列名”的规范形式
2. 去除所有 JOIN 子句中的 ON 部分
3. 去除 FROM 子句中用于多对多关联的 JOIN 子句
4. 在 FROM 子句中，去除所有在 SQL 的其他部分引用过的表。若所有表都被去除，则去除整个 FROM 子句。

后处理过程

1. 将所有在 SQL 中引用过的表添加到 FROM 子句中。
2. 根据外键关系，将数据库中的所有表构造成无向图，并使用 Kruskal 算法求解包含当前 FROM 子句中的表的最小生成树，根据生成树的边和节点来重建 JOIN 子句中的 ON 部分。
3. 有多张表时，恢复别名

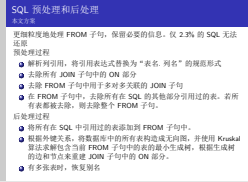

Time: 4:10

SQL 预处理和后处理

本文方案

例

```
SELECT T3.Party_Theme, T2.Name FROM party_host AS T1
    JOIN host AS T2 ON T1.Host_ID = T2.Host_ID
    JOIN party AS T3 ON T1.Party_ID = T3.Party_ID
转换为
SELECT party.Party_Theme, host.Name
```

- 解析别名 T2，T3 为真正的表名
- party_host 是多对多关联表，host 和 party 表均在 SELECT 子句中被引用过，所以整个 FROM 子句全部被去除。

虽然结果也是去除了整个 FROM 子句，但其过程更加细致。可以避免上个例子中信息丢失的情况。

Time: 4:40

上下文编码机制

EditSQL 使用会话级别 RNN 编码上下文信息

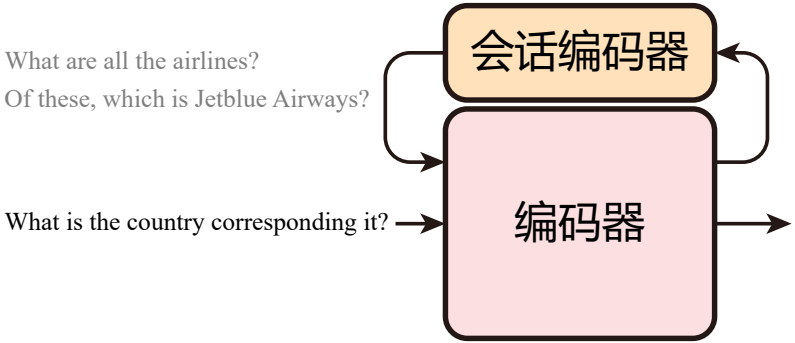

图: EditSQL 编码上下文方案

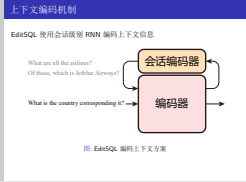

Time: 4:55

上下文编码机制

BERT 等模型经过大规模无标注文本数据预训练，能更好地理解自然语言的上下文信息，如指代、省略等现象。

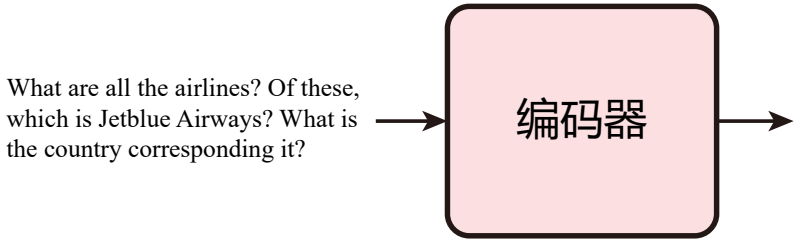

图: 本文上下文编码机制

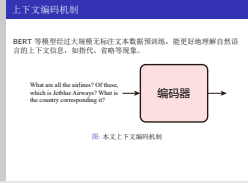

因此，直接串联自然语言查询的上下文，更好地理解

Time: 5:15

关系编码机制

- 数据库架构中包含有主键，外键等信息。这些信息被以往的很多方法忽略
- 本文将数据库架构的编码结合进预训练注意力机制中

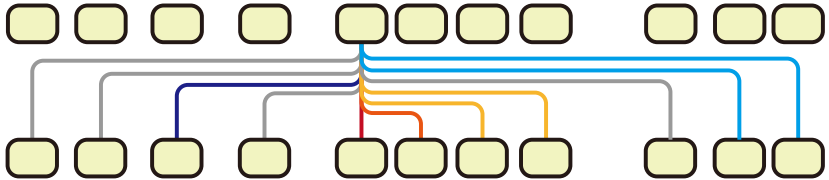

图: 关系编码机制示意[1]

[1]为了展示简洁，标点符号对应的表示已省略，它们全部使用“其他”关系。此处仅展示了部分关系类型。

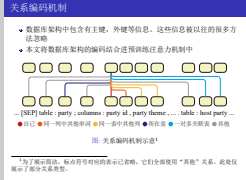

编码有向图
以此帮助模型更好地理解结构化的数据库架构

Time: 5:45

目录

总体结果

	问题准确率	交互准确率
SyntaxSQL-con	18.5	4.3
CD-Seq2Seq	21.9	8.1
EditSQL with BERT	47.2	29.5
本文模型 with BERT	54.3	34.6
本文模型 with XLNet	**58.5**	**39.6**
使用标注的历史 SQL 查询		
EditSQL with BERT	53.4	29.2
本文模型 with BERT	60.7	34.6
本文模型 with XLNet	**64.3**	**39.3**

表: SParC 实验总体结果

总体结果
	问题准确率	交互准确率
SyntaxSQL-con	18.5	4.3
CD-Seq2Seq	21.9	8.1
EditSQL with BERT	47.2	29.5
本文模型 with BERT	54.3	34.6
本文模型 with XLNet	**58.5**	**39.6**
使用标注的历史 SQL 查询		
EditSQL with BERT	53.4	29.2
本文模型 with BERT	60.7	34.6
本文模型 with XLNet	**64.3**	**39.3**
表: SParC 实验总体结果

Time: 6:05

消融实验

SQL 预处理和后处理

- “无 FROM”为 EditSQL 所用方案
- “FROM 未引用表”为本文最终采用方案

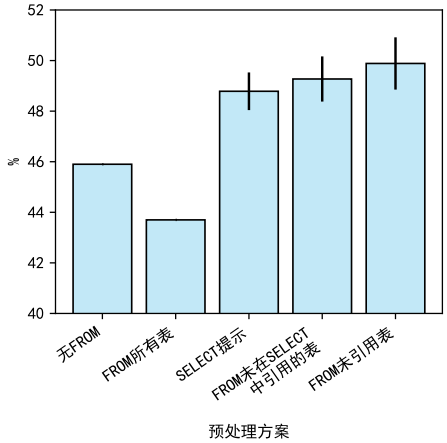

图: 各种预处理方案对比

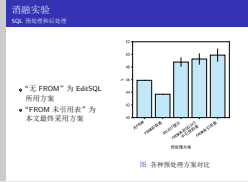

EditSQL 的方案虽然会导致信息丢失，但依然是有助提升性能的。右边 4 个：由此判断要预测的冗余的信息越多，准确率越低。消除冗余是有效提升准确率的方法

Time: 7:05

消融实验

上下文编码 & 关系编码机制

	问题准确率	交互准确率
本文模型	58.5	39.6
- 上下文编码	54.2	33.9
- 关系编码	57.1	38.9

表: 消融实验结果

实验对比结果

- 上下文编码机制虽然简单，但效果显著
- 关系编码机制带来较小提升

Time: 7:15

错误分析

- 大多数错误出现在单个子查询内
- 较高层次的查询骨架错误和较低层次的列选择错误都较多
- 语法错误几乎没有

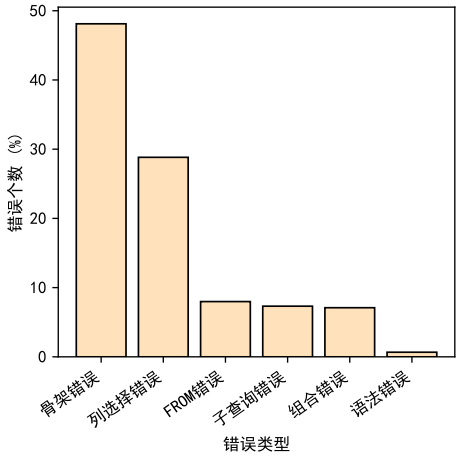

图: 预测错误分析

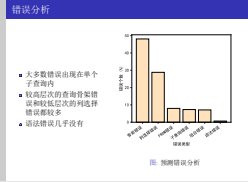

大多查询不包括子查询和组合结构。其预测准确率也很低

Time: 7:35

目录

结论

工作总结

- 提出了三项简单的改进措施，并实验验证其有效
- 融入最新预训练模型 XLNet，进一步提升结果
- 在 SParC 数据集，跨领域上下文相关的自然语言到 SQL 转换任务上，取得了新的最优准确率

工作展望

- 使用类似 ORM 系统的方式，继续改进预处理方案
- 强化关系编码效果，并可应用于其他领域
- 数据库自然语言接口系统的进一步研究与实现

Time: 08:00

1. 设计更适合机器学习预测的，能确定性转换为 SQL 的查询语言
2. 准确率不足以在实际工程项目中